

Mission

L'entreprise **Puls-Events** est une société innovante dans le domaine de la gestion d'événements culturels.

Cette entreprise propose une plateforme web permettant aux utilisateurs de découvrir et de suivre des événements culturels en temps réel.

Le POC d'un chatbot RAG a été réalisé dans une première phase, permettant de valider l'application de cette technologie à l'activité de proposition d'événements culturels.

La mission consiste à définir un projet de passage du POC en **MVP scalable** en élaborant un **rapport de gestion de projet**.

Points majeurs à documenter: synthèse des besoins, choix d'une solution cloud, architecture technique et macro backlog, estimation des coûts, planification.

Périmètre du POC

Outils présélectionnés :

- Environnement virtuel
- Python 3
- LangChain (orchestration)
- Faiss (base de données vectorielle)
- Mistral API (chatbot)

Source de données : [événements publics Open Agenda](#)

Domaine d'application :

- Paris uniquement
- Événements de moins d'un an
- Spectacles vivants et audiovisuels

Architecture et résultats du POC



OpenAgenda

Préparation des données



Chunking

Embeddings Mistral



FAISS

Question utilisateur



Recherche sémantique

Mistral



Réponse

Tests conformes sur :

- 1336 événements nettoyés
- 3383 chunks générés
- 3383 vecteurs indexés dans FAISS

Evaluation :

Un jeu de 24 questions/type de réponses a été défini pour mesurer la qualité des réponses.

Résultat : 22 tests corrects sur 24, soit un taux de réussite de **91,7 %**.

Objectifs du passage au MVP

POC

Exécution locale
Ligne de commande
Index FAISS local

Aucune mémoire persistante
Périmètre Paris fixe
Données internes seulement
Peu de supervision



MVP

Application cloud accessible
Interface web et API
Index centralisé avec pgvector

Historique conversationnel
Recommandations géolocalisées
Recherche web contrôlée
Monitoring complet

Sécurité
RGPD
Performance
Maintenabilité
Scalabilité

Technologies

Fonctionnalités

Contraintes

Parties prenantes et critères de réussite

Groupes principaux d'intervenants

Utilisateurs pilotes

Produit et marketing

Direction ou sponsor

Data et développement

Exploitation

Sécurité et protection des données

Critères de réussite

Chatbot accessible

Pipeline automatisé

Sources identifiables

Mémoire sans mélange de sessions

Prise en compte de la localisation


Recherche web contrôlée

Métriques et alertes disponibles

Aucune anomalie critique

Planification projet sur 12 semaines

Planning prévisionnel du passage du POC au MVP



Tâches principales:

- S1 Cadrage
- S1-S2 Architecture et environnements
- S3-S4 Industrialisation du socle RAG
- S5-S6 Mémoire et localisation
- S7 Recherche web
- S8-S9 Intégration, interface et monitoring
- S10-S11 Qualification et pilote
- S12 Déploiement et Go/No-Go

Chemin critique:

Cadrage → architecture → socle RAG → fonctions prioritaires → intégration → recette → déploiement

Macro-backlog et priorisation

Must-Have (périmètre MVP) 58 jours-homme

Complexité forte

Socle RAG
Mémoire conversationnelle
Contexte géographique
Recherche web
Résilience, sécurité et RGPD
Déploiement, qualité, livraison

Complexité moyenne

Accès au chatbot
Données événementielles
Monitoring technique
Suivi fonctionnel

Nice-to-Have 23 jours-homme


Complexité forte

Personnalisation
Extension géographique
Comptes utilisateurs

Complexité moyenne

Pilotage métier
Alertes d'exploitation

Architecture cloud cible




Raisons du choix d'AWS


- Continuité avec les compétences disponibles
- Intégration cohérente des services
- Déploiement de conteneurs sans gestion de serveurs
- Support de PostgreSQL et pgvector
- Possibilités d'auto scaling
- Portabilité maintenue grâce à Docker, Python et Terraform

Flux conversationnel et flux d'ingestion

Flux synchrone



Flux asynchrone



Industrialisation, sécurité et observabilité

Industrialisation

Docker
GitHub Actions
Terraform
ECR
ECS rolling update
Rollback

Sécurité

Cognito
IAM
Secrets Manager
TLS
Sous-réseaux privés
RGPD

Observabilité

CloudWatch
Logs structurés
Métriques
OpenTelemetry
AWS X-Ray
Alertes

Risques et mesures de mitigation

Risques majeurs

Coût des appels LLM
Indisponibilité d'une API
Réponses non fiables
Fuite de données
Retard du projet
Surcharge technique



Mesures de mitigation

Suivi des tokens, cache, limitation du contexte
Timeouts, retry, fallback
Sources citées, seuils, tests de référence
Chiffrement, secrets, durée de conservation limitée
Priorisation Must-Have/Nice-to-Have
Auto scaling et monitoring

Estimation financière et optimisation

Estimation financière

BUILD : 29 550 €

OPEX : 2 187 €/mois

(pour 500 utilisateurs actifs)

Leviers d'optimisation

Dimensionnement progressif

Réduction des appels LLM

Cache

Limitation de la conservation des logs

Extinction des environnements inutilisés

Alertes budgétaires

Ajustement de la disponibilité au niveau réel de service attendu



Livrables, portfolio et conclusion

Livrables

Rapport de gestion (PDF)
Macro-backlog (Excel)
Estimation Build/OPEX (Excel)
[Dépôt GitHub du Projet 13](#)
[Portfolio GitHub Pages](#)
Présentation de soutenance (PDF)

Liens

Projet 13

<https://github.com/ericginez/rag-poc-to-mvp-project>

Portfolio Pages

<https://ericginez.github.io/>

Dépôt du portfolio

<https://github.com/ericginez/ericginez.github.io>

Le Projet 13 ne livre pas le MVP lui-même : il fournit la trajectoire complète permettant de passer d'un POC validé à un produit cloud déployable, mesurable, sécurisé et financièrement maîtrisé.